

# PERBANDINGAN ALGORITMA LOGISTIC REGRESSION, RANDOM FOREST DAN XGBOOST UNTUK KLASIFIKASI PERSETUJUAN PINJAMAN BANK

Hamdika Putra <sup>1)</sup>, Anna Baita, S.Kom., M.Kom. <sup>2)</sup>

<sup>1)</sup> Informatika, Universitas Amikom Yogyakarta

<sup>2)</sup> Informatika, Universitas Amikom Yogyakarta

email : [<sup>1\)</sup>hamdikaputra@students.amikom.ac.id](mailto:hamdikaputra@students.amikom.ac.id), [<sup>2\)</sup>anna@amikom.ac.id](mailto:anna@amikom.ac.id)

## Abstraksi

Studi ini menguji secara komparatif performa Logistic Regression, Random Forest, dan XGBoost dalam memprediksi persetujuan pinjaman bank. Kami melakukan penelitian ini melalui serangkaian tahapan: pra-pemrosesan data, seleksi fitur, pembagian data, pelatihan model, hingga evaluasi menyeluruh menggunakan metrik akurasi, presisi, recall, dan F1-score. Dataset yang kami gunakan tersusun atas enam fitur krusial, meliputi jumlah pinjaman, suku bunga, pendapatan, kepemilikan rumah, tujuan pinjaman, dan riwayat gagal bayar. Secara signifikan, XGBoost terbukti memberikan akurasi tertinggi di antara algoritma yang diuji. Penemuan ini diharapkan dapat memfasilitasi lembaga keuangan untuk mengotomatisasi dan meningkatkan efisiensi proses seleksi peminjam mereka.

### Kata Kunci :

klasifikasi, persetujuan pinjaman, logistic regression, random forest, xgboost

## Abstract

This study comprehensively compares the performance of three classification algorithms—Logistic Regression, Random Forest, and XGBoost—in predicting bank loan approvals. We conducted the research through stages of data preprocessing, feature selection, data splitting, model training, and a thorough evaluation using accuracy, precision, recall, and F1-score metrics. The dataset utilized in this work comprises six crucial features: loan amount, interest rate, income, home ownership, loan intent, and previous default history. Significantly, XGBoost demonstrated the highest accuracy among the tested algorithms. This discovery is anticipated to empower financial institutions to automate and enhance the efficiency of their borrower selection processes.

### Keywords :

classification, loan approval, logistic regression, random forest, xgboost

## 1. Pendahuluan

Dalam lanskap keuangan modern, melonjaknya permintaan pinjaman dari masyarakat mendesak lembaga finansial untuk mengimplementasikan proses seleksi calon peminjam yang presisi dan efisien. Kemampuan memprediksi kelayakan peminjam menjadi sangat krusial demi menjaga stabilitas keuangan bank dan memitigasi risiko gagal bayar. Oleh karena itu, penerapan metode klasifikasi dalam domain *data mining* menjadi esensial untuk menganalisis data peminjam yang tersedia, sehingga memungkinkan prediksi persetujuan pinjaman secara otomatis dan akurat.

Tinjauan literatur menunjukkan bahwa algoritma *machine learning* telah terbukti efektif dalam memprediksi risiko kredit dan keputusan pinjaman [1], [2]. Secara khusus, *Random Forest* telah menunjukkan konsistensi dalam memberikan hasil prediksi yang stabil dan kuat, bahkan pada dataset dengan fitur yang melimpah dalam sektor keuangan [5], [7]. Di sisi lain, *XGBoost* menonjol karena kapabilitasnya dalam menangani ketidakseimbangan data dan interaksi kompleks antar fitur, seringkali menghasilkan kinerja superior dalam tugas prediksi pinjaman [3], [9]. Sementara itu, *Logistic Regression*, sebagai fondasi model prediktif, tetap relevan berkat

kemampuannya memberikan interpretasi yang jelas dalam penilaian risiko kredit [4].

Melanjutkan studi-studi terdahulu, penelitian ini mengambil langkah lebih jauh dengan membandingkan performa tiga algoritma klasifikasi *Logistic Regression*, *Random Forest*, dan *XGBoost* dari segi akurasi prediksi pada dataset persetujuan pinjaman. Pendekatan komparatif ini sejalan dengan upaya-upaya serupa dalam literatur prediksi risiko kredit [1], [2], [7], namun dengan fokus spesifik pada aplikasi dan perbandingan langsung algoritma-algoritma tersebut dalam konteks persetujuan pinjaman.


## 2. Metode Penelitian

Riset ini menjalankan serangkaian tahapan metodologis yang sistematis guna mencapai tujuannya. Prosesnya dimulai dengan pengumpulan data, diikuti pra-pemrosesan yang cermat. Selanjutnya, kami melakukan pemilihan fitur esensial berdasarkan analisis korelasi yang divisualisasikan menggunakan *heatmap*, sebuah langkah krusial untuk mengidentifikasi variabel-variabel relevan. Setelah itu, tahapan inti berlanjut pada pelatihan model-model klasifikasi yang diusulkan: *Logistic Regression*, *Random Forest*, dan *XGBoost*. Terakhir, performa model dievaluasi secara komprehensif untuk memprediksi persetujuan pinjaman bank.

Seluruh pendekatan ini dirancang untuk membangun model klasifikasi yang efektif dan optimal dalam konteks prediksi tersebut.

## 2.1 Diagram Alir Penelitian

Diagram alir berikut menggambarkan tahapan penelitian secara keseluruhan:



Gambar 2.1 Diagram Alir Penelitian

## 3.1 Penjelasan Tahapan Penelitian

Untuk mencapai tujuan penelitian, studi ini menjalankan serangkaian tahapan metodologis krusial yang dirancang untuk membangun model klasifikasi persetujuan pinjaman bank yang akurat dan sistematis. Rincian tahapan-tahapan ini disajikan pada sub-bagian berikut:

### a. Pengumpulan Data

Sumber data utama dalam penelitian ini berasal dari repositori GitHub, tersedia dalam format .csv dengan nama `loan_data.csv`. Dataset komprehensif ini berisikan informasi rinci mengenai calon peminjam, mencakup variabel numerik seperti jumlah pinjaman (`loan_amnt`), pendapatan (`person_income`), suku bunga (`loan_int_rate`). Selain itu, terdapat juga data kategorikal seperti status kepemilikan rumah (`person_home_ownership`) dan tujuan pinjaman (`loan_intent`). Adapun, variabel target utama untuk proses klasifikasi adalah kolom `loan_status`, yang secara eksplisit mengindikasikan status persetujuan atau penolakan pinjaman.

### b. Eksplorasi Data Awal

Tahapan ini dilakukan dengan fungsi `df.info()`, `df.describe()`, `df.nunique()`, dan `df.isnull().sum()` untuk melihat struktur data, distribusi nilai numerik, jumlah nilai unik, serta mengecek nilai null. Selain itu, dicek juga duplikasi data.

### c. Pra-pemrosesan Data

Langkah pra-pemrosesan data menjadi krusial untuk memastikan data siap diolah oleh model pembelajaran mesin. Tujuan utama dari tahapan ini adalah untuk mengoptimalkan kualitas dan format data agar kompatibel dengan kebutuhan algoritma. Serangkaian langkah penting yang kami terapkan meliputi:

- **Encoding:** Fitur-fitur kategorikal yang teridentifikasi, seperti `loan_intent`, `person_home_ownership`, dan `previous_loan_defaults_on_file`, kami transformasikan menjadi representasi numerik yang dapat dipahami model. Proses konversi ini dilakukan secara efektif menggunakan metode `LabelEncoder`.
- **Normalisasi:** Fitur numerik seperti `loan_amnt`, `loan_int_rate`, dan `person_income` dinormalisasi menggunakan `StandardScaler` untuk menyetarakan skala antar fitur.
- Fitur target `loan_status` tidak diubah karena sudah dalam bentuk numerik biner.

### d. Visualisasi dan Seleksi Fitur

Setelah proses pra-pemrosesan, dilakukan visualisasi hubungan antar fitur melalui **heatmap korelasi** menggunakan `seaborn`. Dari hasil visualisasi, dipilih enam fitur yang paling relevan terhadap variabel target `loan_status`, yaitu:

- `loan_amnt`
- `loan_int_rate`
- `person_income`
- `person_home_ownership`
- `loan_intent`
- `previous_loan_defaults_on_file`

Pemilihan fitur dilakukan secara manual berdasarkan interpretasi visual dan domain knowledge, bukan dengan metode `feature importance`.

### e. Pembagian Data

Untuk mempersiapkan data bagi proses pelatihan dan pengujian, kami membagi dataset menjadi dua segmen utama menggunakan fungsi `train_test_split()` dari pustaka `scikit-learn`. Pembagian ini dilakukan dengan alokasi 80% untuk data latih dan 20% sisanya untuk data uji. Guna menjamin reproduktibilitas hasil penelitian, kami menetapkan parameter acak (`random_state`) ke nilai 42 selama proses pembagian.

### f. Pelatihan Model

Kami melatih tiga algoritma klasifikasi berbeda menggunakan data latih yang telah dipersiapkan. Pemilihan ketiga algoritma ini didasarkan pada karakteristik dan kapabilitasnya masing-masing:

- **Logistic Regression:** Algoritma ini kami manfaatkan sebagai model *baseline*. Keputusannya didasarkan pada kesederhanaan implementasinya dan

kemudahan interpretasi hasilnya, menjadikannya titik acuan yang ideal.

- Random Forest: Sebagai representasi model berbasis *ensemble*, *Random Forest* terpilih karena kemampuannya yang unggul dalam menangani baik fitur numerik maupun kategorikal secara efektif, serta robust terhadap *noise*.
- XGBoost: Algoritma ini kami integrasikan mengingat performanya yang luar biasa dalam mengatasi masalah *overfitting* dan kemampuannya untuk mengelola kompleksitas data dengan sangat baik, menjadikannya pilihan kuat untuk prediksi akurat.

Setiap model yang diuji baik Logistic Regression, Random Forest, maupun XGBoost kami terapkan menggunakan pipeline yang terstruktur atau secara langsung, dengan memanfaatkan parameter default (tanpa tuning hyperparameter).

### g. Evaluasi Model

Model dievaluasi menggunakan data uji berdasarkan metrik berikut:

- Akurasi
- Precision
- Recall
- F1-score

Selanjutnya, kami menyajikan hasil evaluasi performa model secara komprehensif dalam bentuk tabel perbandingan, memungkinkan identifikasi algoritma terbaik. Untuk memperkaya analisis, kami juga mengintegrasikan visualisasi seperti *heatmap* korelasi untuk memahami hubungan antar fitur, serta grafik distribusi fitur terhadap label sebagai alat bantu yang kuat dalam mendukung interpretasi temuan.

## 3. Hasil dan Pembahasan

Pada bagian ini akan dijelaskan hasil-hasil yang diperoleh dari proses klasifikasi persetujuan pinjaman bank menggunakan tiga algoritma yaitu Logistic Regression, Random Forest, dan XGBoost. Hasil penelitian disusun secara sistematis mulai dari evaluasi model, visualisasi data, pembahasan performa algoritma, hingga kelebihan dan kekurangan sistem.

### 3.1 Hasil Evaluasi Model


Pasca selesainya tahapan pra-pemrosesan dan seleksi fitur, kami melanjutkan pada proses pelatihan model. Untuk memastikan robustnya hasil, setiap model dilatih menggunakan teknik validasi silang (*cross-validation*), sebelum kemudian diuji secara menyeluruh menggunakan data uji yang telah dialokasikan. Kami melakukan evaluasi performa model secara cermat, memanfaatkan serangkaian metrik klasifikasi standar, meliputi akurasi, presisi, *recall*, dan *F1-score*, guna menilai efektivitas prediksi secara komprehensif. Hasil evaluasi disajikan pada Tabel 1.

| Model               | Akurasi | Precision | Recall | F1   |
|---------------------|---------|-----------|--------|------|
| Logistic Regression | 0.875   | 0.82      | 0.82   | 0.82 |
| Random Fores        | 0.930   | 0.91      | 0.88   | 0.90 |
| Xgboost             | 0.929   | 0.91      | 0.88   | 0.89 |

Tabel 3.1 Hasil Evaluasi Metrik Model

### 3.2 Visualisasi Korelasi Fitur

Untuk memahami hubungan antar fitur terhadap target *loan\_status*, digunakan visualisasi *heatmap* korelasi. Gambar 1 menampilkan korelasi antar fitur numerik.



Gambar 3.2 Heatmap Korelasi Fitur

Keterangan:

- Warna merah menunjukkan korelasi positif tinggi.
- Warna biru menunjukkan korelasi negatif.

Analisis kami mengungkapkan bahwa fitur *loan\_amnt* (jumlah pinjaman) dan *loan\_int\_rate* (suku bunga) memiliki korelasi positif dengan *loan\_status*. Implikasinya, peningkatan jumlah pinjaman dan tingkat bunga secara signifikan berkorelasi dengan probabilitas penolakan pinjaman yang lebih tinggi. Di sisi lain, kami menemukan *person\_income* (pendapatan) dan *previous\_loan\_defaults\_on\_file* (riwayat gagal bayar sebelumnya) menunjukkan hubungan negatif dengan status pinjaman. Hal ini mengindikasikan bahwa semakin tinggi pendapatan dan ketiadaan catatan gagal bayar di masa lalu, semakin besar pula peluang pinjaman untuk disetujui.

### 3.3 Pembahasan Performa Model

Bagian ini mengulas secara komprehensif performa ketiga algoritma klasifikasi yang kami terapkan, disertai penjelasan mendalam mengenai karakteristik dan relevansinya dalam konteks penelitian ini:

- Logistic Regression: Algoritma linier ini, meskipun tergolong sederhana, terbukti cukup efektif sebagai model *baseline*. Keunggulannya terletak pada transparansi

dalam interpretasi koefisien, memungkinkan pemahaman yang jelas mengenai dampak setiap fitur terhadap probabilitas persetujuan pinjaman.

- Random Forest: Model berbasis *ensemble* ini beroperasi dengan membangun sejumlah besar pohon keputusan, lalu mengintegrasikan hasilnya melalui mekanisme *voting* untuk menghasilkan prediksi akhir. Pendekatan ini berkontribusi pada stabilitas model yang luar biasa, menjadikannya sangat sesuai untuk dataset yang melibatkan kombinasi fitur kategorikal dan numerik.
- XGBoost: Sebagai implementasi canggih dari teknik *gradient boosting*, XGBoost menyempurnakan model secara iteratif dengan fokus pada koreksi kesalahan prediksi sebelumnya. Menariknya, dalam studi ini, meskipun XGBoost adalah algoritma yang sangat kuat, keunggulan *boosting* ini tidak terlalu menonjol dibandingkan Random Forest, kemungkinan besar karena jumlah fitur dalam dataset yang tidak terlalu ekstensif.

Hasil penelitian kami konsisten dengan temuan dalam literatur yang lebih luas, di mana studi-studi lain turut mengindikasikan performa tangguh dari Random Forest dan XGBoost dalam aplikasi klasifikasi persetujuan atau risiko pinjaman. Kedua algoritma *ensemble* ini seringkali berhasil melampaui model linier yang lebih sederhana [7], [9], [10]. Sejumlah penelitian lebih lanjut juga menguatkan argumen bahwa pendekatan *ensemble*, seperti Random Forest dan XGBoost, memiliki kapabilitas superior dalam menangani kompleksitas data finansial dibandingkan Logistic Regression [3], [5].

### 3.4 Formula Evaluasi

Untuk menghitung nilai akurasi dan metrik lainnya digunakan rumus berikut:

$$Akurasi = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Dimana:

- TP: True Positive
- TN: True Negative
- FP: False Positive
- FN: False Negative

Formula ini digunakan untuk mengevaluasi ketepatan dan keandalan dari model klasifikasi.

### 3.5 Analisis Kelebihan dan Kelemahan Sistem

#### Kelebihan Sistem:

Sistem yang kami kembangkan ini menunjukkan beberapa keunggulan signifikan, antara lain:

- Efisiensi Pra-pemrosesan Data: Proses pra-pemrosesan data terbukti efisien dan ringkas, mengingat distribusi label pada dataset kami relatif seimbang. Kondisi ini meniadakan kebutuhan akan teknik *balancing* data yang kompleks seperti SMOTE, mempercepat alur kerja penelitian.
- Akurasi Tinggi Tanpa *Tuning* Ekstensif: Meskipun kami tidak melakukan *hyperparameter tuning* secara mendalam, model Random Forest dan XGBoost secara konsisten memberikan hasil prediksi yang sangat akurat, menggarisbawahi robustnya performa algoritma ini pada dataset yang ada.
- Bantuan Visual dalam Seleksi Fitur: Pemanfaatan visualisasi korelasi secara efektif memfasilitasi proses seleksi fitur. Ini memungkinkan kami untuk mengidentifikasi variabel-variabel yang paling relevan secara langsung terhadap label target, meningkatkan fokus analisis.

#### Kelemahan Sistem:

Meskipun menunjukkan keunggulan, penelitian ini juga mengidentifikasi beberapa keterbatasan yang perlu diperhatikan untuk pengembangan di masa depan:

- Optimasi Model Terbatas: Studi ini belum sepenuhnya mengeksplorasi optimasi model secara mendalam, seperti penerapan metode *grid search* atau teknik *tuning hyperparameter* lainnya, yang berpotensi meningkatkan kinerja model lebih lanjut.
- Generalisasi Model yang Belum Teruji: Model-model yang telah kami kembangkan belum divalidasi dengan dataset eksternal. Akibatnya, kemampuan generalisasi model terhadap data baru atau di luar lingkup dataset penelitian ini masih memiliki ruang untuk diuji lebih lanjut.
- Penyederhanaan Fitur Kategorikal: Penggunaan *LabelEncoder* untuk menyederhanakan beberapa fitur kategorikal berpotensi mengurangi kompleksitas hubungan asli yang mungkin ada dalam data. Hal ini dapat membatasi kemampuan model dalam menangkap nuansa informasi dari fitur-fitur tersebut.

## 4. Kesimpulan

Dalam studi ini, kami telah berhasil membandingkan kinerja Logistic Regression, Random Forest, dan XGBoost untuk prediksi persetujuan pinjaman bank. Temuan kunci menunjukkan bahwa Random Forest

unggul dalam performa keseluruhan, mencapai akurasi sebesar 93%. Algoritma ini diikuti secara berurutan oleh XGBoost dan Logistic Regression.

Sistem yang kami bangun menonjol berkat pemanfaatan fitur-fitur terpilih yang sangat relevan dan penerapan metode evaluasi yang komprehensif, tanpa memerlukan teknik balancing data tambahan karena distribusi label yang seimbang. Kendati demikian, perlu diakui bahwa terdapat beberapa keterbatasan: model belum diuji pada dataset eksternal, dan optimasi parameter secara mendalam belum dilakukan.

Meskipun demikian, hasil kami menegaskan bahwa Random Forest merupakan pilihan yang sangat efektif untuk klasifikasi persetujuan pinjaman berbasis data tabular. Kesimpulan ini selaras dengan literatur yang ada, yang secara konsisten mengkonfirmasi superioritas algoritma ensemble dalam konteks aplikasi keuangan [5], [7].

### Daftar Pustaka

- [1] M. R. Al-Jubouri dan L. K. M. Al-Jobouri, "A Comparative Study of Machine Learning Algorithms for Credit Risk Prediction," *Iraqi Journal of Science*, vol. 63, no. 5, pp. 2486–2495, 2022.
- [2] M. Q. A. Al-Radaideh, "A Comparative Study of Machine Learning Models for Credit Risk Assessment," *Journal of Advances in Computer Engineering and Technology*, vol. 8, no. 1, pp. 1–10, 2022.
- [3] V. M. Kolli, S. K. Singh, dan C. S. Yadav, "Predicting Loan Default Using Machine Learning: A Comparative Analysis," *Procedia Computer Science*, vol. 189, pp. 245–254, 2021.
- [4] C. R. Rao, "Credit Risk Assessment and Prediction using Machine Learning Algorithms," *International Journal of Pure and Applied Mathematics*, vol. 119, no. 17, pp. 1787–1798, 2020.
- [5] A. A. Sharafati, "A Comparative Study of Supervised Machine Learning Algorithms for Credit Scoring," *Journal of Big Data*, vol. 8, no. 1, pp. 1–17, 2021.
- [6] H. K. Singh, "Machine Learning Approaches for Loan Sanction Prediction," *International Journal of Engineering Research & Technology (IJERT)*, vol. 9, no. 6, pp. 182–186, 2020.
- [7] A. G. V. Filho, R. C. V. de Abreu, dan M. R. T. G. Filho, "Predicting Credit Risk: A Comparative Analysis of Machine Learning Techniques," *Expert Systems with Applications*, vol. 178, p. 114889, 2021.
- [8] L. Xiao, X. Li, dan Y. Li, "Loan Default Prediction Based on Machine Learning Algorithms," *Journal of Physics: Conference Series*, vol. 1952, no. 3, p. 032039, 2021.
- [9] X. Zhang, X. Deng, dan X. Li, "An Empirical Study on Loan Default Prediction using Ensemble Machine Learning Methods," *Computers & Operations Research*, vol. 121, p. 104974, 2020.
- [10] S. H. Zaini, A. R. Abdullah, dan M. H. Z. Abidin, "Comparative Analysis of Machine Learning Algorithms for Credit Risk Assessment in Banking Industry," *Journal of Physics: Conference Series*, vol. 2005, no. 1, p. 012028, 2021.
- [11] B. G. Zopounidis dan S. Doumpos, "Machine Learning in Financial Decision Making: An Overview and Future Research Directions," *European Journal of Operational Research*, vol. 296, no. 1, pp. 1–14, 2022.